

Projet - Big Data / IA / Web

Partie IA

FISE3 Brest / Caen / Nantes – 2026



Contexte du projet

Objectif


Concevoir et développer une application d'étude des données IRVE

Approfondir les compétences acquises dans les modules *Big Data*, *Intelligence Artificielle*, *Développement Web* et *Base de Données* à travers une application complète de traitements et de visualisation de données concernant les données provenant de la base nationale des IRVE (Infrastructures de Recharge pour Véhicules Électriques).


Objectifs de la partie Intelligence Artificielle :

- Comprendre les étapes d'un projet d'apprentissage automatique
- Apprendre à évaluer une méthode d'apprentissage automatique
- Manipuler les différentes techniques d'apprentissage automatique :
 - Apprentissage non supervisé : clustering
 - Apprentissage supervisé : classification, régression

Déroulement du projet



Déroulement du projet



Cahier des charges

Besoin client

- 1. Visualisation sur carte :**
 - Créer un visuel sur une carte Map qui regroupe automatiquement les point de recharge par type d'implantation et qui affiche leur position sous la forme d'une carte de chaleur.
- 2. Clustering selon la position :**
 - Faire un clustering selon la position des bornes de recharge.
- 3. Modèle de prédiction pour le type d'implantation :**
 - Développer un modèle d'IA capable de prédire le type d'implantation.
- 4. Modèle de prédiction pour la puissance nominale :**
 - Prédire la puissance nominale des bornes de recharge


5 fonctionnalités principales sont attendues :

1. Préparation des données (pour les besoins client 1, 2, 3 et 4)
2. Apprentissage non-supervisé (pour le besoin client 2)
3. Apprentissage supervisé (pour les besoins client 3 et 4)
4. Métriques (pour les besoins client 2, 3 et 4)
5. Création de scripts utilisables en ligne de commande (pour les besoins client 2, 3 et 4)

Attention

Les fonctionnalités additionnelles que vous développerez seront évaluées uniquement si les fonctionnalités principales sont en place.

Réalisation du Besoin client 1 : Visualisation sur carte




Visualisation sur carte :

- Créer un visuel sur une carte qui regroupe automatiquement les points de charges recharge selon leur type d'implantation.
- Créer une carte de chaleur selon la position des points de charges.
- L'objectif est d'identifier la localisation des points de charges avec leur type et de détecter d'éventuelles anomalies.



Besoin client 1 : Visualisation sur carte


- **Chargement des données :**
 - Chargement du jeu de données obtenus à la fin de la partie Big Data.
- **Préparation des données :**
 - Extraction des données d'intérêt : sélectionner les colonnes pertinentes de la base de données selon ce besoin.
 - Nettoyage des données si nécessaire.
 - Encodage des données catégorielles si nécessaire : utiliser des techniques de prétraitement pour convertir les données non numériques en données numériques si nécessaire. Référez-vous à <https://scikit-learn.org/stable/modules/preprocessing.html>
 - Vérification des données
- **Visualisation des données :**
 - Distribution des types d'implantation et/ou de la puissance nominale avec des graphiques adaptés.
- **Visualisation sur carte selon le type d'implantation et/ou de la puissance nominale :**
 - Création de la carte : utiliser une bibliothèque de visualisation pour représenter les bornes de recharge selon leur type d'implantation et/ou de leur puissance nominale.
- **Création d'une carte de chaleur pour représenter la densité spatiale des bornes :**
 - Création d'une carte de chaleur : utiliser une bibliothèque de visualisation pour afficher la position des points de charge avec une représentation adéquate permettant de visualiser la densité des bornes sur une zone



Les attendus

- Justifier le choix des variables sélectionnées
- Justifier le choix des opérations réalisées pour la préparation des données
- Justifier le choix des méthodes de création des cartes

Réalisation du Besoin client 2 : Clustering selon la position



Besoin client 2 : Clustering selon la position

Apprentissage non-supervisé :

- Mettre en place une méthode de clustering pour partitionner les bornes de recharge selon leur position géographique
- Rechercher le nombre optimal de clusters
- Mesurer la pertinence du clustering



- **Apprentissage non-supervisé :**
 - Choix de l'algorithme de clustering : sélectionner **un/des algorithme(s)** de clustering pour regrouper les bornes de recharge selon leur position. Référez-vous à <https://scikit-learn.org/stable/modules/clustering.html>
 - Détermination du nombre de clusters : expérimenter avec différents nombres de clusters pour voir quel modèle offre le meilleur regroupement.
- **Métriques pour l'apprentissage non-supervisé :**
 - Évaluation des clusters : utiliser des métriques pour évaluer la qualité du clustering. Référez-vous aux méthodes : *Silhouette Coefficient* , *Calinski-Harabasz Index* , *Davies-Bouldin Index*.
- **Visualisation sur une carte :**
 - Création de la carte : utiliser une bibliothèque de visualisation pour représenter les bornes de recharge sur une carte avec des couleurs différentes pour chaque cluster.
- **Préparation d'un script :**
 - Écrire un script prenant en entrée les spécificités d'une borne de recharge et qui renvoie le cluster associé. Un exemple de script est fourni dans les ressources du projet.

Attention : le script ne doit pas relancer une recherche des clusters à chaque usage, il doit impérativement charger le modèle préalablement enregistré.

Les attendus

- Justifier le choix des variables sélectionnées
- Justifier le choix du modèle de clustering + Expliquer le principe de son fonctionnement
- Justifier le choix des métriques et discuter les résultats obtenus (tableau + graphes)

Réalisation du Besoin client 3 : Modèle de prédiction du type d'implantation

Besoin client 3 : Modèle de prédiction du type d'implantation

Modèle de prédiction du type de d'implantation :

- Développer un modèle d'intelligence artificielle capable de prédire le type d'implantation d'une borne.



Besoin client 3 : Modèle de prédiction du type d'implantation

- **Préparation des données :**

- Extraction des données d'intérêt : Sélectionner les colonnes pertinentes de la base de données selon ce besoin.
- Encodage des données catégorielles si besoin.
- Normalisation des données ou pas.
- Cible : `('implantation_station')`
- Utiliser des techniques de prétraitement de données pour préparer les données d'apprentissage. Référez-vous à <https://scikit-learn.org/stable/modules/preprocessing.html>

Attention : Enregistrer vos modèles de prétraitement de données, c'est important pour le script final et la partie Web du projet.

- **Apprentissage supervisé pour la classification :**

- Choix de l'algorithme d'apprentissage : Sélectionner **des algorithmes** d'apprentissage pour prédire le type d'implantation. Référez-vous à https://scikit-learn.org/stable/supervised_learning.html#

- **Métriques pour la classification :**

- Évaluation de résultats de la classification : Utiliser des métriques pour évaluer la qualité du modèle de la classification. Référez-vous à https://scikit-learn.org/stable/modules/model_evaluation.html.
- Utilisation du GridSearchCV pour tester toutes les combinaisons possibles avec **plusieurs hyperparamètres du modèle** et trouver le meilleur modèle de prédiction. Référez-vous à https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

- **Préparation d'un script :**

- Écrire un script prenant en entrée les spécificités d'une borne et qui renvoie la prédiction de son implantation. Un exemple de script est fourni dans les ressources du projet.

Attention : le script ne doit pas relancer un apprentissage à chaque usage, il doit impérativement charger les modèles préalablement enregistrés.

Les attendus

- Justifier le choix des variables sélectionnées (tableau + graphes)
- Justifier le choix du modèle de classification + Expliquer le principe de son fonctionnement
- Justifier le choix des métriques et discuter les résultats obtenus (tableau + graphes)

Réalisation du Besoin client 4 : Modèle de prédiction pour la puissance nominale



Besoin client 4 : Modèle de prédiction de la puissance nominale

Modèle de prédiction de la puissance nominale :

- Développer un modèle d'intelligence artificielle capable de prédire la puissance nominale d'une borne.



Besoin client 4 : Modèle de prédiction de la puissance nominale

- **Préparation des données :**

- Extraction des données d'intérêt : Sélectionner les colonnes pertinentes de la base de données selon ce besoin.
- Encodage des données catégorielles si besoin.
- Normalisation des données ou pas.
- Cible : `('puissance_nominale')`
- Utiliser des techniques de prétraitement de données pour préparer les données d'apprentissage. Référez-vous à <https://scikit-learn.org/stable/modules/preprocessing.html>

Attention : Enregistrer vos modèles de prétraitement de données, c'est important pour le script final et la partie Web du projet.

- **Apprentissage supervisé pour la classification :**

- Choix de l'algorithme d'apprentissage : Sélectionner **des algorithmes** d'apprentissage pour prédire la puissance nominale. Référez-vous à https://scikit-learn.org/stable/supervised_learning.html#

- **Métriques pour la classification :**

- Évaluation de résultats de la classification : Utiliser des métriques pour évaluer la qualité du modèle de la classification. Référez-vous à https://scikit-learn.org/stable/modules/model_evaluation.html.
- Utilisation du GridSearchCV pour tester toutes les combinaisons possibles avec **plusieurs hyperparamètres du modèle** et trouver le meilleur modèle de prédiction. Référez-vous à https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

- **Préparation d'un script :**

- Écrire un script prenant en entrée les spécificités d'une borne et qui renvoie la prédiction de sa puissance. Un exemple de script est fourni dans les ressources du projet.

Attention : le script ne doit pas relancer un apprentissage à chaque usage, il doit impérativement charger les modèles préalablement enregistrés.

Les attendus

- Justifier le choix des variables sélectionnées (tableau + graphes)
- Justifier le choix du modèle de classification + Expliquer le principe de son fonctionnement
- Justifier le choix des métriques et discuter les résultats obtenus (tableau + graphes)

Déroulement

Préparation de l'environnement de travail et gestion de projet :

- Outil de développement : *VSCode*
- Installation des packages : *pandas, sklearn, plotly, folium...*
- *Gantt*
- *Git* si possible

→ **Attendus : diagramme de *Gantt***



Travail en trinôme :

- Chaque étudiant dans le trinôme connaît l'ensemble du projet : **utiliser le gestionnaire de code *Git* si possible**
- Attention à bien se répartir le travail en prévoyant les tâches de chacun avec un **diagramme de Gantt**

Ressources externes :

- Tous les documents sont autorisés
- Attention à utiliser avec une grande précaution tout document extérieur : site de vulgarisation, forum, code d'autrui, IA générative...

Documentation du projet :

- Au fur et à mesure
- Standardisée
- Livraison de code ou de documents :
 - Ne pas attendre la dernière minute pour poster un livrable
 - Préparer des livrables intermédiaires (surtout pour les sources)
 - Sauvegarder régulièrement vos données

Livrables et évaluations

Format de l'archive :

Archive *ZIP*, *TGZ*, *7ZIP*, pas de *RAR* : *projetia_trinomeX.zip* (remplacer X par votre numéro de trinôme)

Le rendu final doit contenir :

- Quatre dossiers : *Besoin_Client_1*, *Besoin_Client_2*, *Besoin_Client_3* et *Besoin_Client_4*
- Dans chaque dossier on doit trouver :
 - La base de données utilisée (.csv)
 - Le Notebook de la partie expérimentale (.ipynb) commenté et exécutable sans erreur
 - Le script final (.py)
 - Les ressources nécessaires (comme les modèles enregistrés (.pkl))
 - Le Readme.txt pour décrire comment utiliser le script final avec un script d'exemple
- Un rapport (.pdf) de 11 pages (dont 1 page de diagramme de *Gantt*) dans lequel sont formalisés les différents attendus

Remarques :

- Malus possible sur l'un des membres du groupe si l'investissement est jugé trop faible
- Possibilité d'être interrogé durant le projet de façon individuelle
- Plagiat sévèrement sanctionné pour TOUS les membres du / des groupe(s)

Attention

Les livrables seront à poster sur l'intranet. Tout retard sera sanctionné (l'heure du réseau faisant foi).
Les fichiers au mauvais format ou avec un mauvais nommage seront pénalisés.

Présentation orale le vendredi (la planification et l'ordre de passage seront fixés par le prof) :

- Soutenance de 10 minutes (strict) + 5 minutes de questions
- Présentation en trinôme (pensez à vous répartir la parole)
- Présentez l'essentiel de votre projet
- Chaque membre de l'équipe présente sa contribution au projet
- Réservez 2 minutes pour exécuter la démonstration des 3 scripts finaux

Code et rapport :

- Rendu de l'intégralité de vos codes sources
- Rapport du trinôme présentant les attendus du projet
- **Aucun code ne doit apparaître dans le rapport et la présentation**

Evaluations des compétences :

- Des questions seront posées tout au long du projet pour vérifier les acquis

Barème indicatif : Soutenance 40% – Compétences 40% – Évaluation du rapport + code 20%

ISEN

ALL IS DIGITAL!



yncréa

MERCI
Des questions ?

